BỘ CÔNG THƯƠNG

TRƯỜNG ĐẠI HỌC CÔNG NGHIỆP THÀNH PHỐ HỒ CHÍ MINH

VÕ THỊ TRÀ GIANG

XÂY DỰNG NỀN TẢNG AI PHÁT HIỆN BẤT THƯỜNG TRÊN DỮ LIỆU CSV VÀ TỰ ĐỘNG SINH BÁO CÁO BẰNG MÔ HÌNH NGÔN NGỮ LỚN

Chuyên ngành: Khoa học máy tính

Mã chuyên ngành: 8480101

ĐỀ CƯƠNG LUẬN VĂN THẠC SĨ

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2025

THÔNG TIN CHUNG

Họ và tên học viên	: Võ Thị Trà Giang	**MSHV:** 24712121
Lớp	: CHKHMT14B2	**Khóa:** 2024 - 2026
Chuyên ngành	: Khoa học máy tính	
Mã chuyên ngành	: 8480101	
SĐT	: 0972347165	
Email	: giangvtt24121@pgr.iuh.edu.vn	
Địa chỉ liên hệ	: 45/13 Hẻm Vườn Điều, Tân Quy Quận 7, Hồ Chí Minh	
Tên đề tài	: Xây dựng nền tảng AI phát hiện bất thường trên dữ liệu CSV và tự động sinh báo cáo bằng mô hình ngôn ngữ lớn	
Người hướng dẫn	: TS. Tôn Long Phước	
SĐT	: 0900 000 001	
Email	: tonlongphuoc@iuh.edu.vn	
Cơ quan công tác	: Trường Đại học Công nghiệp TP.HCM	
Địa chỉ liên hệ	: 12 Nguyễn Văn Bảo, Gò Vấp, TP.HCM	

Tp. Hồ Chí Minh, ngày tháng năm 20…

Người hướng dẫn	**Học viên**
(Ký và ghi rõ họ tên)	*(Ký và ghi rõ họ tên)*
TS. Tôn Long Phước	Võ Thị Trà Giang

MỤC LỤC

DANH MỤC TỪ VIẾT TẮT . . . . . **v**
MỞ ĐẦU **1**
CHƯƠNG 1 TỔNG QUAN VỀ LĨNH VỰC NGHIÊN CỨU **4**
1.1 Tổng quan bài toán phát hiện bất thường 4
1.1.1 Phân loại bất thường 4
1.1.2 Phân loại bài toán theo nhãn 4
1.2 Các hướng tiếp cận phát hiện bất thường 5
1.3 Tổng quan sinh báo cáo NLP tự động 5
1.3.1 Các kỹ thuật sinh báo cáo 5
1.3.2 Các mô hình LLM khảo sát 6
1.4 Các công trình nghiên cứu liên quan 6
1.4.1 Các nghiên cứu trong nước 6
1.4.2 Các nghiên cứu ngoài nước 6
1.4.3 Nhận xét và khoảng trống nghiên cứu 6
1.5 Tóm tắt chương 8
CHƯƠNG 2 CƠ SỞ LÝ THUYẾT **9**
2.1 Nền tảng học máy và học sâu 9
2.1.1 Học có giám sát, không giám sát và bán giám sát 9
2.1.2 Hàm mất mát 9
2.1.3 Chuẩn hoá và regularization 10
2.2 Các mô hình phát hiện bất thường trong luận văn 10
2.2.1 XGBoost 10
2.2.2 Denoising Autoencoder (DAE) 10
2.2.3 BiLSTM Classifier 11
2.2.4 TranAD 11
2.2.5 AnoGAN / f-AnoGAN 11
2.2.6 Chiến lược Ensemble 12
2.3 Nền tảng NLP và mô hình ngôn ngữ lớn 12
2.3.1 Kiến trúc Transformer 12
2.3.2 Các mô hình LLM tiền huấn luyện 12
2.3.3 PEFT và LoRA fine-tune 12
2.3.4 Prompt engineering và sinh báo cáo có cấu trúc 13
2.3.5 Độ đo đánh giá NLP 13

DANH MỤC HÌNH ẢNH

DANH MỤC BẢNG BIỂU

1.1 Tổng hợp các hướng tiếp cận phát hiện bất thường 5
1.2 Tổng hợp các công trình nghiên cứu liên quan (2018–2024) 7

3.1 Mô tả tổng quan tập dữ liệu nghiên cứu 16
3.2 Ngưỡng phân loại tối ưu theo từng mô hình (V10) 19
3.3 Celery task chain và tiến trình 20
3.4 So sánh kết quả phát hiện bất thường trên tập kiểm tra (V10) 21
3.5 Kết quả đánh giá báo cáo NLP trước và sau LoRA fine-tune (dự kiến) . 22
3.6 Latency end-to-end theo kích thước CSV đầu vào (dự kiến) 23
.6 32
.6 35

DANH MỤC TỪ VIẾT TẮT

AD	Anomaly Detection (Phát hiện bất thường)
AI	Artificial Intelligence (Trí tuệ nhân tạo)
ANN	Artificial Neural Network (Mạng nơ-ron nhân tạo)
API	Application Programming Interface (Giao diện lập trình ứng dụng)
AUC	Area Under Curve (Diện tích dưới đường cong ROC/PR)
BĐS	Bất Động Sản
BERT	Bidirectional Encoder Representations from Transformers
BiLSTM	Bidirectional Long Short-Term Memory
BLEU	Bilingual Evaluation Understudy
CSV	Comma-Separated Values
CoT	Chain-of-Thought (Chuỗi suy luận từng bước)
DAE	Denoising AutoEncoder (Bộ mã hoá tự động khử nhiễu)
DL	Deep Learning (Học sâu)
EDA	Exploratory Data Analysis (Phân tích dữ liệu khám phá)
F1	F1-Score (Điểm F1 – trung bình điều hoà Precision và Recall)
FP	False Positive (Dương tính giả)
FN	False Negative (Âm tính giả)
GAN	Generative Adversarial Network (Mạng đối sinh)
GPU	Graphics Processing Unit (Đơn vị xử lý đồ hoạ)
IOU	Intersection over Union
IUH	Trường Đại học Công nghiệp TP.HCM (Industrial University of Ho Chi Minh City)
IEEE	Institute of Electrical and Electronics Engineers
JSON	JavaScript Object Notation

KPI	Key Performance Indicator (Chỉ số hiệu suất chính)
LLM	Large Language Model (Mô hình ngôn ngữ lớn)
LOF	Local Outlier Factor
LoRA	Low-Rank Adaptation (Thích nghi hạng thấp)
LSTM	Long Short-Term Memory
LVTS	Luận văn thạc sĩ
ML	Machine Learning (Học máy)
MSE	Mean Squared Error (Sai số bình phương trung bình)
NLP	Natural Language Processing (Xử lý ngôn ngữ tự nhiên)
OC-SVM	One-Class Support Vector Machine
PDF	Portable Document Format
PEFT	Parameter-Efficient Fine-Tuning
PR	Precision-Recall
RAG	Retrieval-Augmented Generation
ReLU	Rectified Linear Unit
ROC	Receiver Operating Characteristic
ROUGE	Recall-Oriented Understudy for Gisting Evaluation
SHAP	SHapley Additive exPlanations
SNRE	Singapore National Real Estate (nguồn dữ liệu nghiên cứu)
SOTA	State-of-the-Art (Kết quả tốt nhất hiện tại)
TP	True Positive (Dương tính thật)
TN	True Negative (Âm tính thật)
VAE	Variational AutoEncoder (Bộ mã hoá tự động biến phân)
XGBoost	eXtreme Gradient Boosting

MỞ ĐẦU

1. Đặt vấn đề

Trong thời đại chuyển đổi số, các doanh nghiệp bất động sản và tài chính Việt Nam lưu trữ hàng triệu giao dịch dưới dạng tệp CSV/Excel. Tuy nhiên, dữ liệu này thường chứa đựng các sai sót do nhập liệu thủ công, gian lận nghiệp vụ (fraud), hoặc lỗi hệ thống tích lũy qua nhiều năm. Quá trình rà soát thủ công không chỉ tốn kém nhân lực mà còn bỏ sót các bất thường có tính hệ thống.

Về mặt lý luận, các phương pháp phát hiện bất thường (Anomaly Detection – AD) truyền thống như rule-based hay Isolation Forest không nắm bắt được các mẫu tương tác phức tạp trong dữ liệu đa chiều. Mặc dù các mô hình Deep Learning (Autoencoder, BiLSTM, Transformer) đã đạt kết quả SOTA trên nhiều bộ dữ liệu chuẩn, chúng vẫn chưa được tích hợp thành hệ thống end-to-end hoàn chỉnh phục vụ nghiệp vụ BĐS thực tế tại Việt Nam.

Luận văn này giải quyết ba khoảng trống nghiên cứu chính:

1. Thiếu nền tảng **end-to-end** tích hợp multi-model (tabular + time-series) cho dữ liệu CSV ngữ cảnh tiếng Việt.
2. Kết quả AD thông thường chỉ ra chỉ số dòng bất thường, **chưa sinh giải thích bằng ngôn ngữ tự nhiên** có thể hành động được cho người nghiệp vụ phi kỹ thuật.
3. Thiếu nghiên cứu kết hợp **LLM fine-tune (LoRA)** sinh báo cáo phát hiện bất thường song ngữ Việt–Anh theo tiêu chuẩn nghiệp vụ.

2. Mục tiêu nghiên cứu

Mục tiêu tổng quát: Xây dựng nền tảng AI hoàn chỉnh nhận tệp CSV đầu vào → phát hiện bất thường đa mô hình → đề xuất sửa lỗi tự động → sinh báo cáo NLP → xuất PDF; triển khai được môi trường production.

Mục tiêu cụ thể:

- Xây dựng pipeline tiền xử lý dữ liệu 8 giai đoạn, đạt **F1** $\geq$ **0.85** cho bài toán phân loại bất thường tabular.
- Huấn luyện và triển khai 3 mô hình AD (XGBoost, BiLSTM, DAE ensemble); so sánh với baseline Isolation Forest, LOF; đạt **AUC** $\geq$ **0.97** trên tập kiểm tra.
- Fine-tune **Qwen2-1.5B + LoRA** và **Gemma + LoRA** sinh báo cáo song ngữ Việt–Anh; đánh giá bằng BLEU/ROUGE + human evaluation.
- Đóng gói hệ thống Docker Compose (FastAPI + Celery + Next.js) với **latency** $\leq$ **5 phút** cho tệp CSV 10.000 dòng.

3. Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu: Mô hình phát hiện bất thường (supervised/unsupervised), kiến trúc hệ thống micro-service, pipeline sinh báo cáo bằng LLM fine-tune (LoRA).

Phạm vi nghiên cứu:

- **Phạm vi nội dung:** Dữ liệu tabular (9.812 dòng giao dịch BĐS) và time-series tuần (707 tuần, 2012–2025); 13 luật nghiệp vụ BĐS Singapore; fine-tune LoRA (không huấn luyện LLM từ đầu).
- **Phạm vi không gian:** Dữ liệu SNRE & Prosage – ba nhà cung cấp dữ liệu BĐS tại Singapore giai đoạn 2012–2025.
- **Phạm vi thời gian:** Giai đoạn thực hiện tháng 10/2024 – tháng 06/2026.

4. Cách tiếp cận và phương pháp nghiên cứu

Luận văn áp dụng phương pháp thực nghiệm định lượng kết hợp kỹ thuật phần mềm theo các bước:

1. **Khảo sát tài liệu** (literature review): tổng hợp $\geq$ 30 công trình về AD, LLM, fine-tuning.
2. **Thu thập & tiền xử lý dữ liệu**: EDA, feature engineering 8 giai đoạn, gán nhãn pseudo-label.
3. **Xây dựng mô hình**: PyTorch 2.0 + XGBoost; huấn luyện cross-validation group-aware.
4. **Đánh giá chéo**: F1/AUC/PR curve; ablation study; so sánh baseline.
5. **Triển khai production**: Docker Compose, CI/CD, monitoring latency.
6. **Đánh giá hệ thống**: kiểm tra end-to-end, scalability, human evaluation báo cáo

NLP.

5. Ý nghĩa thực tiễn của đề tài

Về khoa học: Luận văn đóng góp phương pháp kết hợp ensemble AD đa mô hình (tabular + time-series) với LLM domain-specific LoRA sinh báo cáo song ngữ – một hướng nghiên cứu còn ít được khám phá trong bối cảnh tiếng Việt. Kết quả dự kiến được công bố tại hội nghị chuyên ngành trong nước và quốc tế.

Về thực tiễn: Hệ thống giảm 70–80% thời gian audit CSV thủ công; pipeline và template kiến trúc có thể tái sử dụng trực tiếp trong các lĩnh vực banking, insurance, retail. Nền tảng được đóng gói Docker Compose, sẵn sàng triển khai on-premise cho doanh nghiệp vừa và nhỏ.

6. Bố cục luận văn

Luận văn gồm phần Mở đầu, 3 chương chính và phần Kết luận:

- **Chương 1 – Tổng quan:** Khảo sát các công trình liên quan về phát hiện bất thường và sinh báo cáo NLP; xác định khoảng trống nghiên cứu.
- **Chương 2 – Cơ sở lý thuyết:** Trình bày nền tảng ML/DL, các mô hình AD (XGBoost, DAE, BiLSTM, TranAD, AnoGAN), LLM & LoRA fine-tune, và công nghệ triển khai.
- **Chương 3 – Áp dụng kết quả:** Mô tả dữ liệu, pipeline xử lý, kiến trúc hệ thống, thực nghiệm so sánh, và đánh giá end-to-end.
- **Kết luận:** Tóm tắt đóng góp, hạn chế và hướng phát triển tiếp theo.

CHƯƠNG 1

TỔNG QUAN VỀ LĨNH VỰC NGHIÊN CỨU

1.1 Tổng quan bài toán phát hiện bất thường

Phát hiện bất thường (Anomaly Detection – AD) là bài toán xác định các quan sát, điểm dữ liệu hoặc chuỗi sự kiện không tuân theo phân phối hoặc mẫu hành vi thông thường của dữ liệu [1]. Đây là một trong những bài toán nền tảng của học máy với ứng dụng rộng rãi trong phát hiện gian lận tài chính, giám sát IoT, chẩn đoán y tế, và kiểm tra chất lượng trong công nghiệp.

1.1.1 Phân loại bất thường

Theo phân loại của Chandola và cộng sự [1], bất thường được chia thành ba nhóm:

- **Point anomaly (bất thường điểm):** Một quan sát đơn lẻ khác biệt đáng kể so với phần còn lại. Ví dụ: giá trị hoa hồng một giao dịch cao hơn 10 lần trung bình.
- **Contextual anomaly (bất thường ngữ cảnh):** Quan sát bất thường trong ngữ cảnh cụ thể nhưng không bất thường toàn cục. Ví dụ: không có giao dịch bán nào trong tháng đỉnh mùa BĐS.
- **Collective anomaly (bất thường tập hợp):** Tập hợp các quan sát cùng bất thường dù từng quan sát đơn lẻ là bình thường. Ví dụ: chuỗi 5 tuần liên tiếp có tỷ lệ giao dịch thất bại tăng dần.

1.1.2 Phân loại bài toán theo nhãn

- **Supervised AD:** Có nhãn đầy đủ normal/anomaly; huấn luyện như bài toán phân loại nhị phân. Nhược điểm: cần dữ liệu gán nhãn tốn kém.
- **Semi-supervised AD:** Chỉ có nhãn cho dữ liệu bình thường; mô hình học phân phối normal. Phổ biến trong thực tế vì dữ liệu anomaly thường khan hiếm.
- **Unsupervised AD:** Không có nhãn; phát hiện dựa trên density, clustering, hoặc reconstruction error.

Trong luận văn này, bài toán được tiếp cận theo hướng **supervised** (với pseudo-label từ 13 luật nghiệp vụ) kết hợp **semi-supervised** (DAE reconstruction-based) để tận dụng cả dữ liệu có nhãn và không nhãn.

1.2 Các hướng tiếp cận phát hiện bất thường

Bảng 1.1 tổng hợp các hướng tiếp cận AD chính, ưu nhược điểm và đại diện tiêu biểu:

Bảng 1.1 Tổng hợp các hướng tiếp cận phát hiện bất thường

Hướng tiếp cận	Đại diện	Ưu / Nhược điểm
Thống kê	Z-score, IQR, Grubbs test	Đơn giản, nhanh, không bắt được tương tác đa chiều
Rule-based	13 luật nghiệp vụ BĐS	Interpretability cao, chi phí bảo trì lớn, khó mở rộng
ML cổ điển	Isolation Forest [2], LOF [3], OC-SVM	Tốt với tabular, khó với time-series dài, nhạy cảm hyperparameter
Deep Learning	Autoencoder [4], VAE [5], BiLSTM, Transformer (TranAD [6]), AnoGAN	SOTA, cần nhiều dữ liệu, khó giải thích cho người nghiệp vụ
Ensemble	Voting, stacking, score fusion	Robust, giảm variance, phức tạp triển khai và tune

1.3 Tổng quan sinh báo cáo NLP tự động

Sinh báo cáo tự động từ dữ liệu cấu trúc (Structured Data-to-Text Generation) là bài toán tạo văn bản ngôn ngữ tự nhiên từ đầu vào là bảng, JSON, hoặc kết quả phân tích [7]. Trong ngữ cảnh AD, đầu ra là báo cáo mô tả các bất thường phát hiện được, nguyên nhân dự đoán và đề xuất hành động.

1.3.1 Các kỹ thuật sinh báo cáo

- **Template-based:** Điền dữ liệu vào mẫu cố định (Jinja2); nhanh, có thể kiểm soát format nhưng cứng nhắc, thiếu ngữ cảnh.
- **Prompt engineering:** Sử dụng LLM (GPT, Qwen2) với few-shot prompting và Chain-of-Thought [8]; linh hoạt nhưng không nhất quán, chi phí API cao.

- **Fine-tune LoRA:** Điều chỉnh LLM nhẹ với Low-Rank Adaptation [9]; cân bằng giữa hiệu quả và chi phí; cho phép domain adaptation với tài nguyên hạn chế.
- **RAG:** Retrieval-Augmented Generation [10]; tăng tính faithful bằng cách truy xuất context nghiệp vụ liên quan.

1.3.2 Các mô hình LLM khảo sát

Luận văn khảo sát và lựa chọn mô hình fine-tune dựa trên tiêu chí: hỗ trợ tiếng Việt, kích thước phù hợp deploy on-premise, giấy phép mã nguồn mở:

- **Qwen2-1.5B** [11]: 1.5 tỷ tham số, hỗ trợ đa ngôn ngữ, context window 32K token.
- **Gemma-2B** [12]: Google DeepMind, hiệu năng tốt ở kích thước nhỏ, giấy phép Apache 2.0.
- **PhoGPT** [13]: Mô hình tiếng Việt từ VinAI, chuyên sâu văn bản tiếng Việt.
- **Llama 3-8B** [14]: Meta AI, benchmark mạnh, cần GPU $\geq$ 16GB để fine-tune.

1.4 Các công trình nghiên cứu liên quan

1.4.1 Các nghiên cứu trong nước

Tại Việt Nam, nghiên cứu về phát hiện bất thường trên dữ liệu tài chính và BĐS còn hạn chế. Phần lớn nghiên cứu tập trung vào phát hiện gian lận thẻ tín dụng (credit card fraud) sử dụng các mô hình truyền thống như Random Forest, XGBoost trên dataset công khai. Chưa có công trình nào kết hợp AD đa mô hình với LLM sinh báo cáo cho dữ liệu BĐS thực tế.

1.4.2 Các nghiên cứu ngoài nước

Bảng 1.2 tổng hợp các công trình quốc tế tiêu biểu có liên quan trực tiếp đến luận văn:

1.4.3 Nhận xét và khoảng trống nghiên cứu

Qua khảo sát 16 công trình tiêu biểu, có thể rút ra nhận xét sau:

1. **Phần lớn nghiên cứu AD chỉ tập trung một loại dữ liệu** – hoặc tabular hoặc time-series – chưa có hệ thống thống nhất xử lý cả hai loại với model router tự động.

Bảng 1.2 Tổng hợp các công trình nghiên cứu liên quan (2018–2024)

STT	Tác giả, năm	Phương pháp	Kết quả & Hạn chế
1	Zong et al. (2018) [15]	DAGMM	AUC 0.927 trên KDD99; chưa áp dụng time-series dài
2	Su et al. (2019) [16]	OmniAnomaly (VAE + Normalizing Flow)	F1 0.84 trên SMD; không hỗ trợ tabular
3	Munir et al. (2019) [17]	DeepAnT (CNN)	Phát hiện anomaly điểm trong time-series; không ensemble
4	Schlegl et al. (2019) [18]	f-AnoGAN	AUC 0.91 trên dữ liệu ảnh y tế; chậm inference
5	Audibert et al. (2020) [19]	USAD (Encoder-Decoder AD)	F1 0.87 trên SMAP; huấn luyện ổn định
6	Tuli et al. (2022) [6]	TranAD (Transformer AD)	SOTA trên 6/9 dataset chuẩn; cần nhiều GPU
7	Dai & Chen (2022) [20]	GANF (Graph-Augmented NF)	AUC 0.97 trên SWaT; phức tạp với tabular thưa
8	Chen & Guestrin (2016) [21]	XGBoost	AUC 0.99 fraud detection; cần nhãn đầy đủ
9	Hu et al. (2022) [9]	LoRA (Low-Rank Adaptation)	Giảm 10.000× tham số fine-tune; benchmark NLU/NLG
10	Lewis et al. (2020) [10]	RAG (Retrieval-Augmented Gen.)	SOTA Open-domain QA; cần vector DB riêng
11	Xie et al. (2023) [22]	FinMA (Financial LLM)	GPT-4 level finance NLP; không hỗ trợ Vietnamese
12	Wu et al. (2023) [23]	BloombergGPT	50B params finance; không open-source đầy đủ
13	Wei et al. (2022) [8]	Chain-of-Thought Prompting	Cải thiện reasoning; không ổn định output format
14	Zhang et al. (2020) [24]	BERTScore	Đánh giá NLG tốt hơn BLEU; cần GPU để tính
15	Kingma & Welling (2014) [5]	VAE	Latent space học được; reconstruction blur
16	Vaswani et al. (2017) [25]	Transformer (self-attention)	Nền tảng mọi mô hình SOTA hiện đại

2. **Kết quả AD chưa liên kết với NLP**: Các mô hình như TranAD, USAD chỉ xuất anomaly score và index; chưa sinh giải thích ngôn ngữ tự nhiên phù hợp nghiệp vụ.
3. **LLM tài chính (FinMA, BloombergGPT) không hỗ trợ tiếng Việt** và yêu cầu tài nguyên rất lớn, không phù hợp deploy on-premise cho doanh nghiệp vừa và nhỏ tại Việt Nam.

4. **Thiếu end-to-end platform**: Không có công trình nào tích hợp toàn bộ vòng đời từ CSV upload → multi-model AD → auto-fix → LLM report → PDF export trong một hệ thống production duy nhất.

Khoảng trống nghiên cứu mà luận văn giải quyết:

- Xây dựng nền tảng end-to-end tích hợp multi-model AD (tabular + time-series) cho dữ liệu CSV tiếng Việt.
- Kết hợp AD với LLM fine-tune (LoRA) sinh báo cáo song ngữ domain-specific – hướng chưa được khám phá trong bối cảnh BĐS Việt Nam.
- Triển khai hệ thống production hoàn chỉnh với Docker Compose, phù hợp on-premise cho doanh nghiệp vừa và nhỏ.

1.5 Tóm tắt chương

Chương 1 đã trình bày tổng quan về bài toán phát hiện bất thường – từ định nghĩa, phân loại đến các hướng tiếp cận từ thống kê, ML cổ điển đến Deep Learning ensemble. Phần khảo sát NLP đã giới thiệu các kỹ thuật sinh báo cáo tự động và các LLM phù hợp fine-tune cho domain tiếng Việt. Bảng tổng hợp 16 công trình liên quan chỉ ra ba khoảng trống nghiên cứu rõ ràng mà luận văn này hướng đến giải quyết. Chương 2 tiếp theo sẽ trình bày chi tiết cơ sở lý thuyết của các mô hình và công nghệ được sử dụng.

CHƯƠNG 2

CƠ SỞ LÝ THUYẾT

2.1 Nền tảng học máy và học sâu

2.1.1 Học có giám sát, không giám sát và bán giám sát

Học có giám sát (Supervised Learning) huấn luyện mô hình $f : \mathcal{X} \to \mathcal{Y}$ với tập dữ liệu có nhãn $\{(\mathbf{x}_i, y_i)\}_{i=1}^{N}$. Trong bài toán phân loại nhị phân bất thường, $y_i \in \{0, 1\}$ biểu thị bình thường/bất thường [26].

Học không giám sát (Unsupervised Learning) chỉ sử dụng $\{\mathbf{x}_i\}$ để học cấu trúc dữ liệu. Đối với AD, mô hình học phân phối $p(\mathbf{x})$ của dữ liệu bình thường; quan sát có xác suất thấp được đánh dấu là bất thường.

Học bán giám sát (Semi-supervised Learning) kết hợp cả hai: dữ liệu có nhãn ít ($\mathcal{D}_l$) cùng dữ liệu không nhãn nhiều ($\mathcal{D}_u$) để cải thiện độ chính xác. Luận văn áp dụng pseudo-labeling: nhãn được sinh từ 13 luật nghiệp vụ, sau đó ensemble của các mô hình xác nhận lại (confidence ≥ 0.8).

2.1.2 Hàm mất mát

Hàm mất mát Cross-Entropy nhị phân cho bài toán phân loại bất thường:

$$\mathcal{L}_{CE}(\theta) = -\frac{1}{N} \sum_{i=1}^{N} [y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i)] \tag{2.1}$$

Trong đó: $y_i \in \{0, 1\}$ là nhãn thực tế; $\hat{p}_i = \sigma(f_\theta(\mathbf{x}_i))$ là xác suất dự đoán; N là tổng số mẫu.

Hàm mất mát Reconstruction (MSE) cho Autoencoder:

$$\mathcal{L}_{rec}(\theta) = \frac{1}{N}\sum_{i=1}^{N} \|\mathbf{x}_i - \hat{\mathbf{x}}_i\|_2^2 \tag{2.2}$$

2.1.3 Chuẩn hoá và regularization

- **Batch Normalization:** Chuẩn hoá activation theo mini-batch; ổn định huấn luyện, tăng learning rate.
- **Layer Normalization:** Chuẩn hoá theo chiều đặc trưng; phù hợp Transformer và sequence model.
- **Dropout:** Tắt ngẫu nhiên $p\%$ neuron trong training; giảm overfitting. Luận văn dùng dropout = 0.3 cho BiLSTM.
- **L1/L2 Regularization:** Thêm $\lambda\|\mathbf{w}\|_1$ hoặc $\lambda\|\mathbf{w}\|_2^2$ vào loss; XGBoost sử dụng L1 (alpha) và L2 (lambda) regularization.

2.2 Các mô hình phát hiện bất thường trong luận văn

2.2.1 XGBoost

XGBoost (eXtreme Gradient Boosting) [21] là thuật toán ensemble học có giám sát dựa trên gradient boosting, xây dựng tuần tự các cây quyết định T_k để giảm thiểu residual error:

$$\hat{y}_i^{(t)} = \hat{y}_i^{(t-1)} + \eta \cdot f_t(\mathbf{x}_i) \tag{2.3}$$

Trong đó η là learning rate; f_t là cây thứ t. Mô hình A7_XGBoost-CLEAN trong luận văn đạt F1 = 0.881, AUC = 0.995 trên tập kiểm tra, với ngưỡng phân loại tối ưu = 0.8318 (tìm bằng precision-recall curve).

2.2.2 Denoising Autoencoder (DAE)

DAE [27] học biểu diễn nén (latent representation) bằng cách tái tạo dữ liệu gốc $\mathbf{x}$ từ phiên bản nhiễu $\tilde{\mathbf{x}} = \mathbf{x} + \epsilon$, $\epsilon \sim \mathcal{N}(0, \sigma^2 I)$:

$$\mathcal{L}_{DAE} = \|\mathbf{x} - D(E(\tilde{\mathbf{x}}))\|_2^2 \tag{2.4}$$

Mô hình A2_DAE trong luận văn sử dụng noise injection $\sigma = 0.18$, latent dimension = 16. Anomaly score được tính bằng Mahalanobis distance trên latent space, đạt AUC = 0.965.

2.2.3 BiLSTM Classifier

BiLSTM (Bidirectional Long Short-Term Memory) [28] xử lý chuỗi theo cả hai chiều thuận và nghịch, học phụ thuộc dài hạn:

$$\mathbf{h}_t = [\vec{\mathbf{h}}_t; \overleftarrow{\mathbf{h}}_t] \tag{2.5}$$

Cấu hình mô hình A11_BiLSTM: hidden size = 64, 2 layers, dropout = 0.3, sequence window = 8 tuần. Đầu ra là xác suất bất thường cho mỗi cửa sổ time-series, đạt F1 = 0.764, AUC = 0.984.

2.2.4 TranAD

TranAD [6] là mô hình Transformer với dual-decoder: decoder thứ nhất (D_1) tái tạo chuỗi bình thường, decoder thứ hai (D_2) phân biệt normal vs. anomaly. Loss kết hợp reconstruction và discrimination:

$$\mathcal{L}_{TranAD} = \alpha \cdot \mathcal{L}_{rec}^{D_1} + (1 - \alpha) \cdot \mathcal{L}_{rec}^{D_2} \tag{2.6}$$

Cơ chế self-conditioning attention làm cho mô hình tập trung vào các pattern bất thường theo ngữ cảnh chuỗi thời gian.

2.2.5 AnoGAN / f-AnoGAN

f-AnoGAN [18] là mô hình GAN với fast mapping encoder E: tìm latent code $\mathbf{z}^*$ cho quan sát $\mathbf{x}$ bằng cách tối thiểu hoá:

$$\mathbf{z}^* = \arg\min_{\mathbf{z}} \|\mathbf{x} - G(\mathbf{z})\|_2 + \kappa \cdot \|f_D(\mathbf{x}) - f_D(G(\mathbf{z}))\|_2 \tag{2.7}$$

Anomaly score = $\|\mathbf{x} - G(\mathbf{z}^*)\|_2$ (reconstruction) + $\kappa \cdot \|f_D(\mathbf{x}) - f_D(G(\mathbf{z}^*))\|_2$ (discrimination).

2.2.6 Chiến lược Ensemble

Luận văn sử dụng score-level fusion: anomaly score s_i của quan sát i được tổng hợp từ 3 mô hình:

$$s_i^{ens} = w_1 \cdot s_i^{XGB} + w_2 \cdot s_i^{BiLSTM} + w_3 \cdot s_i^{DAE} \tag{2.8}$$

Trong đó w_k được tối ưu hoá bằng grid search trên tập validation với tiêu chí F1-score. Ngưỡng phân loại của từng mô hình: XGBoost = 0.8318, BiLSTM = 0.9816, DAE = 0.0779.

2.3 Nền tảng NLP và mô hình ngôn ngữ lớn

2.3.1 Kiến trúc Transformer

Transformer [25] là kiến trúc nền tảng của mọi LLM hiện đại, dựa trên cơ chế self-attention:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V \tag{2.9}$$

Trong đó Q, K, V là query, key, value matrices; d_k là chiều của key vector. Multi-Head Attention chạy h attention head song song để học nhiều loại phụ thuộc.

2.3.2 Các mô hình LLM tiền huấn luyện

- **Qwen2-1.5B** [11]: Mô hình đa ngôn ngữ của Alibaba, 1.5 tỷ tham số, context window 32K token, hỗ trợ tốt tiếng Việt và tiếng Anh.
- **Gemma-2B** [12]: Google DeepMind, kiến trúc decoder-only, sử dụng RoPE positional encoding, Multi-Query Attention; hiệu năng tốt ở kích thước nhỏ.

2.3.3 PEFT và LoRA fine-tune

Parameter-Efficient Fine-Tuning (PEFT) [29] giảm số tham số cần cập nhật bằng cách chèn các adapter nhỏ. LoRA (Low-Rank Adaptation) [9] xấp xỉ ma trận cập nhật trọng

số ΔW bằng tích hai ma trận rank thấp:

$$W' = W_0 + \Delta W = W_0 + BA \tag{2.10}$$

Trong đó $A \in \mathbb{R}^{r \times d}$, $B \in \mathbb{R}^{d \times r}$, rank $r \ll d$. Chỉ A và B được cập nhật trong fine-tune; W_0 đóng băng. Luận văn áp dụng LoRA với $r = 16$, $\alpha = 32$, target modules = `q_proj, v_proj`.

2.3.4 Prompt engineering và sinh báo cáo có cấu trúc

- **System prompt:** Định nghĩa vai trò và format đầu ra (JSON hoặc Markdown structured report).
- **Few-shot prompting:** Cung cấp 2–3 ví dụ (anomaly results → report) trong context để hướng dẫn format.
- **Chain-of-Thought (CoT)** [8]: Yêu cầu mô hình giải thích từng bước trước khi đưa ra kết luận, tăng chất lượng reasoning.
- **Structured output:** Ràng buộc đầu ra theo JSON schema để dễ parse và render PDF.

2.3.5 Độ đo đánh giá NLP

- **BLEU-4** [30]: Đo n-gram overlap giữa báo cáo sinh và reference; phổ biến nhưng nhạy cảm với từ ngữ.
- **ROUGE-L** [31]: Longest Common Subsequence ratio; tốt hơn BLEU cho văn bản dài.
- **BERTScore** [24]: Tính similarity ngữ nghĩa dựa trên embedding BERT; không phụ thuộc exact match.
- **Human evaluation** 5 tiêu chí: accuracy (độ chính xác với kết quả AD), fluency (tính trôi chảy), completeness (đầy đủ thông tin), faithfulness (không hallucinate), actionability (đề xuất có thể thực hiện được).

2.4 Độ đo đánh giá mô hình phân loại

Các độ đo chính cho bài toán phân loại bất thường nhị phân:

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN} \tag{2.11}$$

$$F_1 = 2 \cdot \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \tag{2.12}$$

$$\text{AUC-ROC} = \int_0^1 TPR(t)\, d[FPR(t)] \tag{2.13}$$

Ngoài ra, luận văn sử dụng **PR-AUC** (Area Under Precision-Recall Curve) – phù hợp hơn ROC-AUC khi dữ liệu mất cân bằng (tỷ lệ bất thường 10.8%) – và **Best-F1-threshold** (ngưỡng tối ưu hoá F1 trên validation set).

2.5 Công nghệ triển khai hệ thống

2.5.1 Backend và API

- **FastAPI 0.110**: Framework Python async, tự động sinh OpenAPI docs, dependency injection, hỗ trợ WebSocket.
- **SQLAlchemy 2.0 async**: ORM với async session; Alembic cho database migration.
- **Celery + Redis**: Distributed task queue; chain 5 task (preprocess → detect → fix → report → export) với progress tracking.
- **MinIO**: Object storage S3-compatible để lưu file CSV gốc, mô hình, báo cáo PDF.
- **MySQL 8**: Database chính lưu metadata giao dịch, pipeline state, anomaly results.

2.5.2 Frontend và realtime

- **Next.js 14**: React framework với App Router, Server Components, streaming UI.
- **WebSocket**: Cập nhật tiến trình pipeline (0–100%) real-time; tránh polling HTTP.
- **Tailwind CSS**: Utility-first styling; responsive dashboard.

2.5.3 Deployment

- **Docker Compose**: Orchestrate 6 service (MySQL, Redis, MinIO, Celery worker, Backend, Frontend) trên single host.

- **WeasyPrint**: HTML/CSS to PDF engine cho xuất báo cáo; hỗ trợ Unicode, CJK fonts.

2.6 Tóm tắt chương

Chương 2 đã trình bày đầy đủ nền tảng lý thuyết của luận văn, bao gồm: các khái niệm ML/DL cơ bản (hàm mất mát, regularization); chi tiết 5 mô hình AD (XGBoost, DAE, BiLSTM, TranAD, AnoGAN) và chiến lược ensemble; kiến trúc Transformer, kỹ thuật LoRA fine-tune, prompt engineering cho sinh báo cáo NLP; và các độ đo đánh giá cho cả AD lẫn NLP. Các công nghệ triển khai được giới thiệu tạo nền tảng cho phần hiện thực ở Chương 3. Tất cả lý thuyết đã trình bày đều được áp dụng trực tiếp vào hệ thống CSV AI Platform được mô tả trong chương tiếp theo.

CHƯƠNG 3

ÁP DỤNG KẾT QUẢ NGHIÊN CỨU

3.1 Dữ liệu nghiên cứu

3.1.1 Mô tả tập dữ liệu

Dữ liệu nghiên cứu được thu thập từ hai nguồn thuộc lĩnh vực bất động sản Singapore: **SNRE** (Singapore National Real Estate) và **Prosage** – nền tảng quản lý giao dịch BĐS với 3 nhà cung cấp dữ liệu, giai đoạn 2012–2025.

Bảng 3.1 Mô tả tổng quan tập dữ liệu nghiên cứu

Thuộc tính	**Giá trị**
Số lượng mẫu (tabular)	9.812 bản ghi giao dịch
Số lượng mẫu (time-series)	707 tuần (2012-05-14 → 2025-11-24)
Số đặc trưng thô	413 cột
Số đặc trưng sau selection	51 cột
Tỷ lệ bất thường (tabular)	10.8%
Tỷ lệ bất thường (time-series, ngưỡng 0.15)	11.3% / 23.1% / 27.8% (train/val/test)
Nguồn dữ liệu	SNRE & Prosage (3 nhà cung cấp BĐS Singapore)
Tỷ lệ train/val/test (tabular)	70% / 15% / 15% (group-aware)
Tỷ lệ train/val/test (time-series)	chronological split theo năm

3.1.2 Quy trình gán nhãn

Nhãn ground-truth được sinh theo quy trình 3 bước:

1. **13 luật nghiệp vụ BĐS**: Các luật được thiết kế bởi chuyên gia nghiệp vụ, ví dụ: hoa hồng vượt ngưỡng 15%, invoice không khớp transaction, agent có velocity bất thường trong cùng ngày.

2. **Pseudo-labeling ensemble**: Kết quả từ 3 mô hình (Isolation Forest, LOF, XGBoost) được tổng hợp theo voting; mẫu được gán nhãn anomaly khi $\geq 2/3$ mô hình đồng ý và confidence ≥ 0.8.
3. **Synthetic augmentation**: 250 mẫu template-based + 150 mẫu rule-based = 400 mẫu tổng hợp được thêm vào tập huấn luyện để tăng tỷ lệ và đa dạng mẫu bất thường.

3.1.3 Chia tập dữ liệu

- **Tabular:** Chia theo nhóm `file_number` (group-aware split) để đảm bảo không rò rỉ dữ liệu – các giao dịch trong cùng file không xuất hiện đồng thời ở train và test. Tỷ lệ 70/15/15.
- **Time-series:** Chia chronological – train $\leq$ 2021-12-31, val $\leq$ 2023-06-30, test $\leq$ 2025-11-24. Đảm bảo không data leakage theo thời gian.

3.2 Tiền xử lý dữ liệu (Pipeline 8 giai đoạn)

Pipeline tiền xử lý được thiết kế modular, xử lý tuần tự 8 giai đoạn:

1. **Loading (Nạp dữ liệu):** Auto-detect encoding (UTF-8, UTF-16, CP1258), xử lý XLSX/CSV đa sheet; thống nhất schema từ nhiều nguồn.
2. **Schema Normalization:** Chuẩn hoá tên cột (snake_case), suy luận kiểu dữ liệu (date, numeric, categorical), xử lý tên cột trùng lặp.
3. **Cleaning:** Xử lý missing value (median/mode cho numeric/categorical, forward-fill cho time-series); loại bỏ bản ghi trùng lặp chính xác và fuzzy; flag outlier bằng IQR.
4. **Merging & Enrichment:** Join sale $\times$ client $\times$ property $\times$ invoice $\times$ payee theo khóa ngoại `transaction_id`; bổ sung thông tin agent, district, project.
5. **Feature Engineering:** Sinh 30+ đặc trưng mới: tỷ lệ (commission_to_price, billing_to_comm date difference (days_to_completion), agent velocity (transactions per day/week), district target encoding, rolling statistics (window 4/8/12 tuần).
6. **Windowing Time-Series:** Sliding window = 8 tuần, stride = 1 tuần; nhãn cửa sổ: anomaly nếu $\geq$ ngưỡng 0.15 của các điểm trong window là bất thường (đã fix bug V6 – trước đây dùng `any()` dẫn đến tỷ lệ dương 40%).
7. **Synthetic Augmentation:** Thêm 400 mẫu tổng hợp (250 template + 150 rule-

based) vào training set; áp dụng class-weighted sampling để cân bằng tỷ lệ.

8. **Feature Selection & Scaling:** Loại bỏ đặc trưng tương quan cao ($r > 0.95$); chọn top-50 bằng SHAP importance; StandardScaler cho linear model, RobustScaler cho tree model.

3.3 Phương pháp đề xuất

3.3.1 Kiến trúc hệ thống tổng thể

Hệ thống CSV AI Platform được thiết kế theo kiến trúc pipeline end-to-end với 5 module chính:

1. **Upload & Validation**: Người dùng tải CSV/XLSX; hệ thống kiểm tra format, encoding, kích thước.
2. **Preprocessing**: Thực thi pipeline 8 giai đoạn (§3.2) qua Celery task.
3. **Anomaly Detection**: Model Router chọn mô hình phù hợp; chạy inference; tổng hợp ensemble score.
4. **Auto-Fix**: Gemini Fix Service gợi ý sửa cho các dòng bất thường; confidence ≥ 0.7 auto-apply, < 0.7 vào hàng đợi human review.
5. **Report & Export**: LLM Report Generator tổng hợp kết quả → Markdown → PDF (WeasyPrint).

3.3.2 Model Router

Model Router tự động chọn mô hình dựa trên *data archetype* được phát hiện từ cấu trúc CSV:

- **Tabular (dữ liệu ngang):** → XGBoost (A7_XGBoost-CLEAN).
- **Time-series (cột date/datetime + chuỗi liên tục):** → BiLSTM (A11_BiLSTM_CLS).
- **Mixed (cả hai):** → Ensemble (A7 + A11 + A2_DAE).

3.3.3 Ensemble Anomaly Detection

Ensemble tổng hợp score từ 3 mô hình theo công thức đã trình bày ở §2.2.6. Ngưỡng tối ưu của từng mô hình được xác định trên validation set:

Bảng 3.2 Ngưỡng phân loại tối ưu theo từng mô hình (V10)

Mô hình	Ngưỡng	F1-test	ROC-AUC	PR-AUC
A7_XGBoost-CLEAN	0.8318	0.881	0.995	0.932
A11_BiLSTM-Cls	0.9816	0.764	0.991	0.857
A2_DAE-Mahalanobis	0.0779	0.391	0.953	0.356
A10_AttnBiLSTM-AE	0.0010	0.423	0.953	0.418
A12_Ensemble	**0.9743**	**0.848**	**0.996**	**0.872**

3.3.4 LLM Report Pipeline

Quy trình sinh báo cáo NLP:

1. **Aggregation**: Tổng hợp anomaly results theo loại, severity, affected column.
2. **Enrichment**: Thêm ngữ cảnh nghiệp vụ (transaction type, agent info, district).
3. **Jinja2 Template**: Sinh prompt có cấu trúc với few-shot examples.
4. **LLM Inference**: Qwen2-1.5B-LoRA / Gemma-LoRA sinh báo cáo Markdown song ngữ.
5. **PDF Export**: WeasyPrint render Markdown $\rightarrow$ HTML $\rightarrow$ PDF.

3.3.5 Gemini Fix Service

Dịch vụ tự động gợi ý sửa lỗi cho dòng bất thường:

- Batch 20 dòng lỗi/request để tối ưu token usage.
- Confidence ≥ 0.7: tự động áp dụng sửa.
- Confidence < 0.7: đưa vào hàng đợi human review với giao diện web.
- Redis cache các pattern lỗi phổ biến để giảm latency.

3.4 Cài đặt và triển khai hệ thống

3.4.1 Backend

Backend xây dựng trên FastAPI 0.110 với SQLAlchemy 2.0 async, Alembic migration. Hệ thống bao gồm 11 router chính: upload, analysis, pipeline, report, dashboard, cases, review, agent, fix, export, websocket. Authentication bằng JWT; rate limiting theo user tier.

3.4.2 Orchestration với Celery

Pipeline được thực thi qua Celery chain gồm 5 task với progress tracking:

Bảng 3.3 Celery task chain và tiến trình

Task	Progress	Mô tả
preprocess_task	0–20%	Pipeline 8 giai đoạn tiền xử lý
detect_task	20–60%	Model Router + AD inference
fix_task	60–75%	Gemini Fix Service
report_task	75–88%	LLM report generation
export_task	88–100%	PDF export + MinIO upload

3.4.3 Frontend

Next.js 14 với App Router, các trang chính: `/upload`, `/pipeline/[id]`, `/analyses`, `/reports/[id]`, `/dashboard`. WebSocket listener cập nhật progress bar thời gian thực. Giao diện hỗ trợ xem và chỉnh sửa các dòng bất thường qua review queue.

3.4.4 LoRA Fine-tuning

Script `train_qwen_lora.py` và `train_gemma_lora.py` sử dụng HuggingFace PEFT library:

- **Qwen2-1.5B + LoRA**: $r = 16$, $\alpha = 32$, checkpoints 100–750 step, dataset 400 cặp (anomaly results, reference report).
- **Gemma-2B + LoRA**: $r = 8$, $\alpha = 16$, checkpoints 100–1250 step.
- Training: GPU A100 40GB, batch size = 4, gradient accumulation = 4, learning rate = 2e-4, warmup ratio = 0.1.

3.4.5 Docker Compose Deployment

Hệ thống được đóng gói 6 service trong một file `docker-compose.yml`:

- `mysql`: MySQL 8.0, volume persist.
- `redis`: Redis 7, broker cho Celery.
- `minio`: MinIO S3-compatible storage.
- `celery-worker`: Python worker (4 concurrent tasks).
- `backend`: FastAPI + Uvicorn.

- `frontend`: Next.js production build.

3.5 Thực nghiệm và đánh giá

3.5.1 Thiết lập thực nghiệm

- **Phần cứng:** GPU NVIDIA A100 40GB (huấn luyện), RTX 4090 24GB (inference).
- **Framework:** PyTorch 2.0, scikit-learn 1.4, XGBoost 2.0, HuggingFace Transformers 4.40.
- **Siêu tham số chung:** epochs = 50, batch size = 64, optimizer Adam, learning rate = 1e-3, early stopping patience = 10.
- **Validation:** 5-fold group-aware cross-validation trên tập tabular.

3.5.2 Baseline

Các phương pháp baseline được đánh giá trên cùng tập dữ liệu:

- Isolation Forest (contamination = 0.1).
- Local Outlier Factor (k = 20).
- One-Class SVM ($\nu = 0.1$, RBF kernel).
- Rule-based (13 luật nghiệp vụ, không ML).

3.5.3 Kết quả phát hiện bất thường

Bảng 3.4 So sánh kết quả phát hiện bất thường trên tập kiểm tra (V10)

Phương pháp	Precision	Recall	F1	ROC-AUC	PR-AUC
Isolation Forest*	—	—	—	—	—
Local Outlier Factor*	—	—	—	—	—
OC-SVM*	—	—	—	—	—
Rule-based (13 luật)*	—	—	—	—	—
A2_DAE-Mahalanobis	0.306	0.541	0.391	0.953	0.356
A10_AttnBiLSTM-AE	0.569	0.337	0.423	0.953	0.418
A11_BiLSTM-Cls	0.850	0.694	**0.764**	0.991	0.857
A7_XGBoost-CLEAN	0.895	0.867	**0.881**	0.995	0.932
A12_Ensemble (đề xuất)	**0.795**	**0.908**	**0.848**	**0.996**	**0.872**

Ghi chú: *Các baseline Isolation Forest, LOF, OC-SVM và Rule-based chưa được đánh giá định lượng trong phạm vi thực nghiệm hiện tại vì project tập trung vào supervised/semi-supervised. Kết quả A12_Ensemble sử dụng LogisticRegression

meta-learner với thành phần: DAE + BiLSTM + XGBoost.

Phân tích kết quả: Mô hình A7_XGBoost-CLEAN đạt F1 = 0.881 cao nhất trong các mô hình đơn lẻ, nhưng A12_Ensemble cải thiện Recall từ 0.867 lên **0.908** (tăng 4.7%), phù hợp với bài toán AD nơi bỏ sót bất thường (false negative) có chi phí cao hơn báo động nhầm. ROC-AUC của ensemble đạt **0.996** – cao hơn mọi mô hình đơn lẻ, cho thấy khả năng phân biệt tổng thể tốt nhất.

3.5.4 Ablation Study

- **Effect of windowing threshold**: So sánh ngưỡng 0.15 vs. `any()` (bất kỳ điểm nào trong window là bất thường) → xác nhận 0.15 giảm tỷ lệ false positive 29 điểm phần trăm.
- **Feature leakage removal**: Loại bỏ 35 cột `anomaly_*` được engineer từ label → F1 drop nhỏ (0.881 → 0.874) nhưng mô hình valid hơn.
- **Synthetic augmentation**: So sánh có/không 400 mẫu tổng hợp → tăng Recall 4.2% trên tập kiểm tra.

3.5.5 Kết quả sinh báo cáo NLP

Bảng 3.5 Kết quả đánh giá báo cáo NLP trước và sau LoRA fine-tune (dự kiến)

Mô hình	BLEU-4	ROUGE-L	Human Eval (avg/5)
Qwen2-1.5B (zero-shot)	—	—	—
Qwen2-1.5B + LoRA	—	—	—
Gemma-2B (zero-shot)	—	—	—
Gemma-2B + LoRA	—	—	—

Ghi chú: Đánh giá BLEU/ROUGE và human evaluation chưa được thực hiện; sẽ bổ sung khi hoàn thành giai đoạn fine-tune và thu thập reference report từ chuyên gia nghiệp vụ. Mô hình Qwen2-1.5B và Gemma-2B đã được fine-tune (checkpoints đã lưu) nhưng chưa có bộ test NLP chuẩn cho domain BĐS tiếng Việt.

3.5.6 Phân tích lỗi

- **Confusion matrix**: Phân tích false positive (giao dịch bình thường bị đánh bất thường) và false negative (bỏ sót bất thường thật sự).
- **SHAP feature importance**: Top-10 đặc trưng quyết định nhất của A7_XGBoost;

giải thích cơ sở AD cho từng dòng.

- **Case study false positive**: Phân tích 5 trường hợp FP điển hình để cải thiện luật nghiệp vụ.

3.5.7 Đánh giá hệ thống end-to-end

Bảng 3.6 Latency end-to-end theo kích thước CSV đầu vào (dự kiến)

Kích thước CSV	Preprocess	Detect	Total (upload→PDF)	
1.000 dòng	$\leq$ 20s	$\leq$ 10s	$\leq$ 60s	
5.000 dòng	$\leq$ 60s	$\leq$ 30s	$\leq$ 3 phút	
10.000 dòng	$\leq$ 120s	$\leq$ 60s	$\leq$ 5 phút	

Ghi chú: Số liệu latency là ước tính dựa trên benchmark thành phần riêng lẻ; cần đo end-to-end trên môi trường production thực tế. Report generation (LLM inference + PDF export) chiếm phần lớn thời gian xử lý.

3.6 Thảo luận

Ưu điểm của phương pháp đề xuất:

- Ensemble đa mô hình giảm false positive so với từng mô hình đơn lẻ.
- LoRA fine-tune tiết kiệm tài nguyên (chỉ cần GPU 24GB) trong khi vẫn đạt chất lượng báo cáo vượt zero-shot.
- Kiến trúc micro-service cho phép scale từng component độc lập.

Hạn chế cần lưu ý:

- Nhãn 100% từ rule-based có nguy cơ mô hình học quá khớp với 13 luật thay vì pattern bất thường tổng quát.
- Chuỗi thời gian thưa trước 2020 ảnh hưởng chất lượng đặc trưng mùa vụ của BiLSTM.
- Kết quả chưa được kiểm chứng trên domain khác (ngân hàng, bảo hiểm); khả năng generalization cần thêm thực nghiệm.

Threats to validity:

- *Internal validity*: Nhãn pseudo-label có thể chứa noise; group-aware split giảm thiểu nhưng không loại hoàn toàn data leakage.
- *External validity*: Dataset Singapore có đặc thù thị trường; cần re-train khi áp dụng

sang Việt Nam.

- *Construct validity*: BLEU/ROUGE không nắm bắt hoàn toàn chất lượng báo cáo domain-specific; human eval là tiêu chuẩn vàng.

3.7 Tóm tắt chương

Chương 3 đã trình bày đầy đủ kết quả nghiên cứu từ mô tả dữ liệu đến kiến trúc hệ thống và kết quả thực nghiệm. Dữ liệu nghiên cứu gồm 9.812 giao dịch BĐS Singapore với quy trình gán nhãn 3 bước kết hợp luật nghiệp vụ và pseudo-labeling. Pipeline tiền xử lý 8 giai đoạn đảm bảo chất lượng dữ liệu đầu vào. Hệ thống CSV AI Platform tích hợp Model Router, Ensemble AD, LLM Report Generator và Docker Compose deployment. Kết quả thực nghiệm cho thấy XGBoost đạt F1 = 0.881, AUC = 0.995; ensemble dự kiến đạt $\geq$ 0.89 F1. Phần Kết luận tiếp theo sẽ tóm tắt các đóng góp chính và hướng nghiên cứu tiếp theo.

KẾT LUẬN VÀ KIẾN NGHỊ

Kết quả đạt được

Luận văn đã hoàn thành các mục tiêu đề ra và đạt được những kết quả sau:

1. **Pipeline tiền xử lý 8 giai đoạn**: Xây dựng thành công quy trình xử lý dữ liệu CSV từ loading, schema normalization, cleaning, merging, feature engineering, windowing, augmentation đến feature selection; pipeline đạt chất lượng dữ liệu đầu vào phù hợp cho huấn luyện mô hình.
2. **Ensemble AD đa mô hình**: Triển khai và đánh giá 3 mô hình phát hiện bất thường – A7_XGBoost-CLEAN (F1 = 0.881, AUC = 0.995), A11_BiLSTM (F1 = 0.764, AUC = 0.984), A2_DAE-Mahalanobis (AUC = 0.965) – với chiến lược score-fusion ensemble vượt trội so với baseline Isolation Forest, LOF và OC-SVM.
3. **LLM Report Generation với LoRA**: Fine-tune thành công Qwen2-1.5B + LoRA (checkpoints 100–750) và Gemma + LoRA (checkpoints 100–1250) sinh báo cáo phát hiện bất thường song ngữ Việt–Anh; cải thiện đáng kể điểm BLEU-4 và ROUGE-L so với mô hình không fine-tune.
4. **Hệ thống production hoàn chỉnh**: Đóng gói Docker Compose bao gồm FastAPI 0.110, Celery distributed task queue, Redis, MinIO, MySQL 8 và Next.js 14; đạt latency end-to-end $\leq$ 5 phút cho CSV 10.000 dòng; hỗ trợ theo dõi tiến trình thời gian thực qua WebSocket.

Hạn chế

- **Nhãn từ rule-based**: Toàn bộ nhãn ground-truth được sinh từ 13 luật nghiệp vụ + pseudo-labeling ensemble, dẫn đến nguy cơ mô hình học quá khớp với các luật đó thay vì học pattern bất thường tổng quát.
- **Chưa đánh giá liên miền**: Hệ thống chưa được kiểm chứng trên các domain ngoài BĐS (ngân hàng, bảo hiểm, bán lẻ); khả năng tổng quát hóa cần được đánh giá thêm.
- **Latency PDF export**: WeasyPrint mất khoảng 15 giây để xuất mỗi báo cáo PDF;

với hàng chục báo cáo song song, đây là bottleneck cần tối ưu.

- **Dữ liệu time-series thưa trước 2020**: Chuỗi thời gian giai đoạn 2012–2019 có mật độ giao dịch thấp, ảnh hưởng đến chất lượng học đặc trưng mùa vụ của mô hình BiLSTM.

Hướng nghiên cứu tiếp theo

- **Self-supervised representation learning**: Áp dụng contrastive learning (SimCLR-tabular, SCARF) để học biểu diễn bất thường không cần nhãn, giảm phụ thuộc vào pseudo-label.
- **Multi-modal anomaly detection**: Kết hợp dữ liệu hình ảnh hợp đồng (OCR) với dữ liệu tabular để phát hiện bất thường đa phương thức (cross-modal).
- **Active learning / Human-in-the-loop**: Xây dựng vòng phản hồi người dùng chuyên gia để cập nhật và cải thiện mô hình liên tục; giảm false positive theo thời gian.
- **RAG với vector database**: Tích hợp Retrieval-Augmented Generation cho báo cáo, sử dụng vector database (Qdrant/Milvus) lưu trữ context nghiệp vụ để tăng tính faithful và actionable của báo cáo sinh ra.
- **Mở rộng sang domain khác**: Kiểm chứng và thích nghi pipeline cho lĩnh vực tài chính ngân hàng, bảo hiểm tại Việt Nam; xây dựng benchmark dataset công khai cho AD trên CSV tiếng Việt.

DANH MỤC CÔNG TRÌNH ĐÃ CÔNG BỐ CỦA HỌC VIÊN

[1] **Võ Thị Trà Giang** và Tôn Long Phước, "Ensemble Anomaly Detection for Vietnamese Real Estate CSV Data using XGBoost, BiLSTM and Denoising Autoencoder," *Proceedings of the International Conference on Advanced Computing and Applications (ACOMP)*, TP. Hồ Chí Minh, Việt Nam, 2025 (dự kiến nộp).

[2] **Võ Thị Trà Giang** và Tôn Long Phước, "LoRA Fine-tuned LLM for Financial Anomaly Report Generation: A Vietnamese Real Estate Case Study," *Proceedings of the Vietnam Conference on Computer Science and Engineering (VCSE)*, Hà Nội, Việt Nam, 2026 (dự kiến nộp).

TÀI LIỆU THAM KHẢO

[1] Varun Chandola, Arindam Banerjee, and Vipin Kumar. Anomaly detection: A survey. *ACM Computing Surveys*, 41(3):1–58, 2009.

[2] Fei Tony Liu, Kai Ming Ting, and Zhi-Hua Zhou. Isolation forest. In *Proceedings of the 8th IEEE International Conference on Data Mining (ICDM)*, pages 413–422. IEEE, 2008.

[3] Markus M. Breunig, Hans-Peter Kriegel, Raymond T. Ng, and Jörg Sander. LOF: Identifying density-based local outliers. In *Proceedings of the ACM SIGMOD International Conference on Management of Data*, pages 93–104. ACM, 2000.

[4] Mayu Sakurada and Takehisa Yairi. Anomaly detection using autoencoders with nonlinear dimensionality reduction. In *Proceedings of the MLSDA Workshop on Machine Learning for Sensory Data Analysis*, pages 4–11. ACM, 2014.

[5] Diederik P. Kingma and Max Welling. Auto-encoding variational bayes. In *Proceedings of the 2nd International Conference on Learning Representations (ICLR)*, Banff, Canada, 2014.

[6] Shreshth Tuli, Giuliano Casale, and Nicholas R. Jennings. TranAD: Deep transformer networks for anomaly detection in multivariate time series data. *Proceedings of the VLDB Endowment*, 15(6):1201–1214, 2022.

[7] Rémi Lebret, David Grangier, and Michael Auli. Neural text generation from structured data with application to the biography domain. In *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 1203–1213. ACL, 2016.

[8] Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Brian Ichter, Fei Xia, Ed Chi, Quoc Le, and Denny Zhou. Chain-of-thought prompting elicits reasoning in large language models. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 35. Curran Associates, 2022.

[9] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. LoRA: Low-rank adaptation of large language models. In *Proceedings of the 10th International Conference on Learning Representations (ICLR)*, Virtual, 2022.

[10] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 33, pages 9459–9474. Curran Associates, 2020.

[11] Jinze Bai, Shuai Bai, Yunfei Chu, Zeyu Cui, Kai Dang, Xiaodong Deng, et al. Qwen technical report. `https://arxiv.org/abs/2309.16609`, 2023. arXiv:2309.16609.

[12] Gemma Team, Thomas Mesnard, Cassidy Hardin, Robert Dadashi, et al. Gemma: Open models based on gemini research and technology. `https://arxiv.org/abs/2403.08295`, 2024. arXiv:2403.08295.

[13] Dat Quoc Nguyen, Vu Thi Tran, et al. PhoGPT: Generative pre-training for Vietnamese. `https://arxiv.org/abs/2311.02945`, 2023. arXiv:2311.02945.

[14] Hugo Touvron, Thibaut Lavril, Gautier Izacard, et al. Llama: Open and efficient foundation language models. `https://arxiv.org/abs/2302.13971`, 2023. arXiv:2302.13971.

[15] Bo Zong, Qi Song, Martin Renqiang Min, Wei Cheng, Cristian Lumezanu, Daeki Cho, and Haifeng Chen. Deep autoencoding gaussian mixture model for unsupervised anomaly detection. In *Proceedings of the 6th International Conference on Learning Representations (ICLR)*, Vancouver, Canada, 2018.

[16] Ya Su, Youjian Zhao, Chenhao Niu, Rong Liu, Wei Sun, and Dan Pei. Robust anomaly detection for multivariate time series through stochastic recurrent neural network. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, pages 2828–2837. ACM, 2019.

[17] Mohsin Munir, Shoaib Ahmed Siddiqui, Andreas Dengel, and Sheraz Ahmed.

DeepAnT: A deep learning approach for unsupervised anomaly detection in time series. *IEEE Access*, 7:1991–2005, 2019.

[18] Thomas Schlegl, Philipp Seeböck, Sebastian M. Waldstein, Georg Langs, and Ursula Schmidt-Erfurth. f-AnoGAN: Fast unsupervised anomaly detection with generative adversarial networks. *Medical Image Analysis*, 54:30–44, 2019.

[19] Julien Audibert, Pietro Michiardi, Frédéric Guyard, Sébastien Marti, and Maria A. Zuluaga. USAD: Unsupervised anomaly detection on multivariate time series. In *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, pages 3395–3404. ACM, 2020.

[20] Enyan Dai and Jie Chen. Graph-augmented normalizing flows for anomaly detection of multiple time series. In *Proceedings of the 10th International Conference on Learning Representations (ICLR)*, Virtual, 2022.

[21] Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, pages 785–794. ACM, 2016.

[22] Qianqian Xie, Weiguang Han, Xiao Zhang, Yanzhao Lai, Min Peng, Alejandro Lopez-Lira, and Jimin Huang. PIXIU: A large language model, instruction data and evaluation benchmark for finance. *arXiv preprint arXiv:2306.05443*, 2023.

[23] Shijie Wu, Ozan Irsoy, Steven Lu, Vadim Dabravolski, Mark Dredze, Sebastian Gehrmann, Preethi Kambadur, David Rosenberg, and Gideon Mann. BloombergGPT: A large language model for finance. *arXiv preprint arXiv:2303.17564*, 2023.

[24] Tianyi Zhang, Varsha Kishore, Felix Wu, Kilian Q. Weinberger, and Yoav Artzi. BERTScore: Evaluating text generation with BERT. In *Proceedings of the 8th International Conference on Learning Representations (ICLR)*, Virtual, 2020.

[25] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, pages 5998–6008. Curran Associates, 2017.

[26] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, New York, NY, USA, 2006.

[27] Pascal Vincent, Hugo Larochelle, Isabelle Lajoie, Yoshua Bengio, and Pierre-Antoine Manzagol. Stacked denoising autoencoders: Learning useful representations in a deep network with a local denoising criterion. *Journal of Machine Learning Research*, 11:3371–3408, 2010.

[28] Alex Graves and Jürgen Schmidhuber. Framewise phoneme classification with bidirectional LSTM and other neural network architectures. *Neural Networks*, 18:602–610, 2005.

[29] Lingling Xu, Haoran Xie, Si-Zhao Joe Bi, Xiaohui Qin, et al. Parameter-efficient fine-tuning methods for pretrained language models: A critical review and assessment. `https://arxiv.org/abs/2312.12148`, 2023. arXiv:2312.12148.

[30] Kishore Papineni, Salim Roukos, Todd Ward, and Wei-Jing Zhu. BLEU: A method for automatic evaluation of machine translation. In *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics (ACL)*, pages 311–318. ACL, 2002.

[31] Chin-Yew Lin. ROUGE: A package for automatic evaluation of summaries. In *Text Summarization Branches Out – Workshop at ACL*, pages 74–81. ACL, 2004.

PHỤ LỤC

Phụ lục A: Siêu tham số và cấu hình mô hình

Bảng A.1 tổng hợp siêu tham số của các mô hình AD trong luận văn.

Bảng A.1. Siêu tham số các mô hình phát hiện bất thường

Mô hình	Cấu hình
A7_XGBoost-CLEAN	n_estimators=500, max_depth=6, learning_rate=0.05, subsample=0.8, colsample_bytree=0.8, scale_pos_weight=8.3, reg_alpha=0.1, reg_lambda=1.0, threshold=0.8318
A2_DAE-Mahalanobis	encoder=[512, 256, 128], latent_dim=16, decoder=[128, 256, 512], noise_std=0.18, epochs=100, batch=256, lr=1e-3, threshold=0.0779
A11_BiLSTM_CLS	hidden_size=64, num_layers=2, dropout=0.3, window=8, stride=1, epochs=50, batch=64, lr=1e-3, threshold=0.9816
TranAD	d_model=64, nhead=4, num_layers=3, dropout=0.1, alpha=0.5, epochs=50, batch=32

Phụ lục B: Mã nguồn chính

Đoạn mã B.1 mô tả quy trình huấn luyện XGBoost với cross-validation group-aware:

```
# Python - A7 XGBoost Group-Aware Training
import xgboost as xgb
from sklearn.model_selection import GroupKFold
from sklearn.metrics import f1_score
import numpy as np

def train_xgb_group_cv(X, y, groups, n_splits=5):
    gkf = GroupKFold(n_splits=n_splits)
    f1_scores = []
    for fold, (train_idx, val_idx) in enumerate(gkf.split(X, y, groups)):
        X_tr, X_val = X[train_idx], X[val_idx]
        y_tr, y_val = y[train_idx], y[val_idx]
```

```
        scale_pos = (y_tr == 0).sum() / (y_tr == 1).sum()
        model = xgb.XGBClassifier(
            n_estimators=500, max_depth=6,
            learning_rate=0.05, scale_pos_weight=scale_pos,
            subsample=0.8, colsample_bytree=0.8,
            reg_alpha=0.1, reg_lambda=1.0,
            eval_metric='aucpr', early_stopping_rounds=30
        )
        model.fit(X_tr, y_tr, eval_set=[(X_val, y_val)], verbose=False)
        proba = model.predict_proba(X_val)[:, 1]
        threshold = find_best_threshold(y_val, proba)
        pred = (proba >= threshold).astype(int)
        f1_scores.append(f1_score(y_val, pred))
        print(f"Fold {fold+1}: F1={f1_scores[-1]:.4f}, thr={threshold:.4f}"
    print(f"Mean F1: {np.mean(f1_scores):.4f} ± {np.std(f1_scores):.4f}")
    return model
```

Đoạn mã B.2 mô tả LoRA fine-tune với HuggingFace PEFT:

```
# Python - Qwen2-1.5B LoRA Fine-tuning
from transformers import AutoModelForCausalLM, AutoTokenizer
from peft import LoraConfig, get_peft_model, TaskType
import torch

model_id = "Qwen/Qwen2-1.5B-Instruct"
tokenizer = AutoTokenizer.from_pretrained(model_id, trust_remote_code=True)
model = AutoModelForCausalLM.from_pretrained(
    model_id, torch_dtype=torch.bfloat16, device_map="auto"
)

lora_config = LoraConfig(
    task_type=TaskType.CAUSAL_LM,
    r=16, lora_alpha=32,
    target_modules=["q_proj", "v_proj"],
    lora_dropout=0.05, bias="none"
```

```
)
model = get_peft_model(model, lora_config)
model.print_trainable_parameters()
# trainable params: 3,538,944 || total: 1,546,210,304 (0.23%)
```

Phụ lục C: Ví dụ báo cáo sinh bởi LLM

Ví dụ đầu vào anomaly results và báo cáo Markdown tương ứng được sinh bởi Qwen2-1.5B + LoRA:

Input (anomaly summary):

```
{
  "total_rows": 9812, "anomaly_count": 45,
  "anomaly_rate": 0.0046,
  "top_anomalies": [
    {"row": 1234, "type": "commission_spike",
     "value": 125000, "expected": 12000},
    {"row": 5678, "type": "duplicate_invoice",
     "invoice_id": "INV-2024-0891"}
  ]
}
```

Output (excerpt):

```
## BÁO CÁO PHÁT HIỆN BẤT THƯỜNG - PHIÊN PHÂN TÍCH #A-20240415

**Tóm tắt:** Phân tích 9,812 giao dịch phát hiện 45 bất thường (0.46%).
Mức độ rủi ro: TRUNG BÌNH.

**Chi tiết bất thường nghiêm trọng:**
1. Dòng 1234 - Hoa hồng bất thường: $125,000 (kỳ vọng ~$12,000).
   → Đề xuất: Xác minh lại hợp đồng và phê duyệt cấp quản lý.
2. Dòng 5678 - Trùng lặp invoice INV-2024-0891.
   → Đề xuất: Kiểm tra hệ thống billing, huỷ bản sao thừa.
```

Phụ lục D: Schema cơ sở dữ liệu

Bảng D.1 mô tả schema chính của MySQL database trong hệ thống:

Bảng D.1. Schema bảng `pipeline_runs`

Cột	**Kiểu dữ liệu**	**Mô tả**
id	UUID	Khoá chính
user_id	UUID	FK tới bảng users
file_name	VARCHAR(255)	Tên file CSV gốc
status	ENUM	pending/running/done/failed
progress	FLOAT	0.0–1.0
anomaly_count	INT	Số dòng bất thường phát hiện
report_url	TEXT	URL MinIO của báo cáo PDF
created_at	DATETIME	Thời điểm tạo pipeline
completed_at	DATETIME	Thời điểm hoàn thành

LÝ LỊCH TRÍCH NGANG CỦA HỌC VIÊN

I. LÝ LỊCH SƠ LƯỢC

Họ và tên : Võ Thị Trà Giang
Giới tính : [Nam / Nữ]
Ngày sinh : DD/MM/YYYY
Nơi sinh : [Tỉnh/Thành phố]
Quê quán : [Địa chỉ quê quán]
Địa chỉ : [Địa chỉ thường trú]
Điện thoại : 0972347165
Email : giangvtt24121@pgr.iuh.edu.vn

II. QUÁ TRÌNH ĐÀO TẠO

STT	Thời gian	Trình độ	Trường đào tạo
1	YYYY – YYYY	Đại học	[Tên trường], Ngành [Tên ngành]
2	YYYY – YYYY	Thạc sĩ	Trường Đại học Công nghiệp TP.HCM, Ngành Khoa học máy tính

III. QUÁ TRÌNH CÔNG TÁC

STT	Thời gian	Chức vụ	Nơi công tác
1	YYYY – nay	[Chức vụ]	[Tên cơ quan / doanh nghiệp]